

机器学习作业 PRML-HW25f03

一.

1. 机器学习: 定义

① 计算机并不用先前编程能力的学习领域。

② 使用经验 $experience$, 表现在任务 $Task$ 上, 用评价指标评价

Performance Measure

③ 人工智能的分发, 定义计算机不用过显式编程而从数据中学习的程序。

2. 监督学习:

使用已知标签的数据进行训练。

非监督学习: 训练数据没有标签。

3.

线性回归模型: $h_w(x) = \underline{w_0} + \underline{w_1}x$

目标: 确定参数 w .

↓ 方法

损失函数 $J(w_0, w_1) = \frac{1}{2m} \sum_{i=1}^m (h_w(x^{(i)}) - y^{(i)})^2$ 的最小值 $\arg \min_{w_0, w_1} J(w_0, w_1)$

在确定参数后进一步观测

4. 损失函数 $J(w_0, w_1) = \frac{1}{2m} \sum_{i=1}^m (h_w(x^{(i)}) - y^{(i)})^2$

① 使用求平方误差, 得到平均平方误差, 代表模型对每个样本的模型误差。

② 再来就是简化复杂的求导过程的不梯度计算过程。

5. 逻辑回归为什么用于分类: 通过 Sigmoid 函数将线性回归的结果映射到 $(0, 1)$ 区间, 将该区间值解释为“样本属于正类的概率”, 再通过设定阈值将概率转化为离散的分类结果。

步骤:

- ① 构建线性模型及训练数据
- ② 通过 sigmoid 函数将结果转化为概率
- ③ 设定阈值确定分类结果

6. 二分类器 组合构造: 多分类器



策略:

① 一对一: (One-vs-One, OvO)

每类训练个二分类器, 复杂度 $O(N, M) = \frac{N \times (N-1)}{2 \times 1} = \frac{N(N-1)}{2}$

问题: 分类器数量随类别数呈平方增长

复杂度: $O(N^2)$

② 一对多 (One-vs-Rest, OvR)

苹果 + 橙子 → 是/不是苹果

问题: 类别数不平衡时, 分类器偏向负类, 预测准确率降低

香 + 橙子

预测准确率降低

橙子 + 香

复杂度: $O(N)$

③ 多对多 (Many-vs-Many, MvM)

问题: 编码规则设计复杂, 且解释性差。

复杂度: $O(M)$

↑
编码长度

苹果	1 (2)	1 (2)
香	1 (2)	0 (1)
橙	0 (1)	1 (2)

第一位

第二位

①
↓
0/1

②
↓
0/1

其他: ① 层次化分类

e.g. 是否喜欢吃

② 集成式多类神经网络

7. 判别函数: 用于分类任务的非线性函数, 通过计算样本的特征值输入, 输出一个用于判定样本所属类别的值。

优点: 计算效率高, 可解释性强, 鲁棒性较好

缺点: 仅适用于线性可分数据集, 特征表达能力弱, 对类别不平衡的数据

8. 线性回归模型:

误差来源

① 模型偏差 (Bias)

减小策略

提升模型复杂度, 更换更灵活的模型

② 模型方差 (Variance)

正则化, 数据增强, 减小模型

③ 随机噪声 (Noise)

数据清洗, 特征工程

9. 过拟合: 模型过度拟合训练数据集的特征, 导致其在训练集上误差极小, 但在未见过的测试数据集或新数据集上泛化能力差, 预测误差显著增高的现象。

10. Univariate Linear Regression 单变量线性回归

Supervised Learning 监督学习 Cost Function 损失函数

Gradient descent 梯度下降

Multivariate Linear Regression 多元线性回归

Features ~~偏差~~ 特征 Bias 偏差 Regularization 正则化

Overfitting 过拟合 Maximum likelihood 最大似然

Least squares 最小二乘 Decision surface 决策面

Perceptron 感知机 Error Function 误差函数

Logistic Regression 逻辑回归

二、线性回归 $y = w^T x + b$

1. Cost function $J(w, b) = \frac{1}{2m} \sum_{i=1}^m (h(x^{(i)}) - y^{(i)})^2$

$$= \frac{1}{2m} \sum_{i=1}^m (w^T x^{(i)} + b - y^{(i)})^2$$

$$\begin{aligned} 2. \quad w^{(k+1)} &= w^{(k)} - \frac{\partial J(w, b)}{\partial w} \cdot \alpha \\ &= w^{(k)} - \frac{1}{m} \sum_{i=1}^m (w^T x^{(i)} + b - y^{(i)}) \cdot x^{(i)} \cdot \alpha \end{aligned}$$

$$\begin{aligned} b^{(k+1)} &= b^{(k)} - \frac{\partial J(w, b)}{\partial b} \cdot \alpha \\ &= b^{(k)} - \frac{1}{m} \sum_{i=1}^m (w^T x^{(i)} + b - y^{(i)}) \cdot \alpha \end{aligned}$$

$$3. \quad J(w, b) = \frac{1}{2m} \left[\sum_{i=1}^m \left(\frac{h(x^{(i)}) - y^{(i)}}{w^T x^{(i)} + b} \right)^2 + \lambda \sum_{j=1}^n w_j^2 \right]$$

$$\begin{aligned} w^{(k+1)} &= w^{(k)} - \frac{\partial J(w, b)}{\partial w} \cdot \alpha \\ &= w^{(k)} - \frac{1}{m} \left[\sum_{i=1}^m \frac{w^T x^{(i)} + b}{h(x^{(i)}) - y^{(i)}} x^{(i)} + \lambda \sum_{j=1}^n w_j \right] \cdot \alpha \end{aligned}$$

$$\begin{aligned} b^{(k+1)} &= b^{(k)} - \frac{\partial J(w, b)}{\partial b} \cdot \alpha \\ &= b^{(k)} - \frac{1}{m} \left[\sum_{i=1}^m (w^T x^{(i)} + b - y^{(i)}) \right] \cdot \alpha \end{aligned}$$

三、感知器

$$1. \quad y(x) = f(w^T \varphi(x))$$

← 权重向量 ← 特征向量

$$f(a) = \begin{cases} +1, & a \geq 0 \\ -1, & a < 0 \end{cases}$$

预测误差: $y_i(w^T x_i + b) \leq 0$

2. 更新: $w^{(t+1)} = w^{(t)} - \eta \nabla E_p(w) = w^{(t)} + \eta \text{cost}_i$

3. 感知器收敛定理

若训练数据集是线性可分的, 则感知器学习算法经过有限次迭代后一定收敛, 能找到一可行的权重向量 w 和偏置 b , 使得对于所有训练样本 (x_i, y_i) , 都有 $y_i(w^T x_i + b) > 0$

四、逻辑回归

1. $J(w) = \frac{1}{n} \sum_{i=1}^m \text{cost}(h_w(x^{(i)}), t^{(i)})$

$$\text{cost}(h_w(x), t) = \begin{cases} -\log h_w(x), & \text{if } t=1 \\ -\log(1-h_w(x)), & \text{if } t=0 \end{cases}$$

$$\Rightarrow \text{cost}(h_w(x), t) = -t \log h_w(x) - (1-t) \log(1-h_w(x))$$

$$J(w) = -\frac{1}{n} \sum_{i=1}^m [t \log h_w(x) + (1-t) \log(1-h_w(x))]$$

2. $w_j = w_j - \alpha \frac{\partial J(w)}{\partial w_j}$

$$h_w(x) = g(w^T x) \quad \begin{matrix} \uparrow \\ g(z) = \frac{1}{1+e^{-z}} \end{matrix} \quad z = w^T x$$

$$g'(z) = g(z)(1-g(z))$$

$$\frac{\partial J}{\partial w} = -\frac{1}{n} \sum_{i=1}^m \left[t^{(i)} \frac{1}{h_w(x^{(i)})} \frac{\partial h_w(x^{(i)})}{\partial w} + (1-t^{(i)}) \frac{1}{1-h_w(x^{(i)})} \frac{\partial h_w(x^{(i)})}{\partial w} \right]$$

$$\frac{\partial h_w(x)}{\partial w} = \frac{\partial g(w^T x)}{\partial w} = \frac{\partial g(z)}{\partial z} \frac{\partial z}{\partial w} = g'(z) x$$

$$= -\frac{1}{n} \sum_{i=1}^m [t^{(i)} x^{(i)} (1-h_w(x^{(i)})) + (1-t^{(i)}) x^{(i)} h_w(x^{(i)})]$$

$$= -\frac{1}{n} \sum_{i=1}^m [t^{(i)} x^{(i)} - x^{(i)} h_w(x^{(i)})]$$

$$= \frac{1}{n} \sum_{i=1}^m (h_w(x^{(i)}) - t^{(i)}) x^{(i)}$$

$$= x \cdot g'(w^T x) = x \cdot g(w^T x) [1-g(w^T x)] = x \cdot h_w(x) [1-h_w(x)]$$

$$3. J(w) = -\frac{1}{m} \sum_{i=1}^m [t^{(i)} \log h_w(x^{(i)}) + (1-t^{(i)}) \log (1-h_w(x^{(i)}))] + \lambda \sum_{j=1}^n w_j$$

4. 通过观测数据集 $D = \{(x_i, y_i)\}_{i=1}^m$ 推断 $P(w|D)$

$$P(w|D) = \frac{P(wD)}{P(D)} = \frac{P(w)P(D|w)}{P(D)}$$

$$P(w|D) \propto P(w)P(D|w)$$

寻找使 $P(w|D)$ 最大的 w .
(最大化后验概率)

实验项

先验项 $P(w)$

反映对参数 w 的先验知识

$$\prod_{i=1}^m P(y_i|x_i; w)$$

五.

$$1. f(w_i) = \frac{e^{w_i} - e^{-w_i}}{e^{w_i} + e^{-w_i}}$$

$$\frac{\partial f}{\partial w_i} = \frac{(e^{w_i} + e^{-w_i})^2 - (e^{w_i} - e^{-w_i})^2}{(e^{w_i} + e^{-w_i})^2} = \left| -\left(\frac{e^{w_i} - e^{-w_i}}{e^{w_i} + e^{-w_i}} \right)^2 \right|$$

$$2. f(x) = \frac{1}{2} x^T x = \frac{1}{2} (x_1^2 + x_2^2 + \dots + x_n^2)$$

$$\nabla_x f(x) = \frac{\partial f}{\partial x} = x$$

$x = \begin{bmatrix} x_1 \\ x_2 \\ \vdots \\ x_n \end{bmatrix}$

$$3. f(x) = \frac{1}{2} x^T A x + b^T x$$

$$\nabla_x f(x) = \frac{\partial f}{\partial x} = Ax + b$$