

这份PDF是关于**线性模型：分类 (Linear Models: Classification)** 的课程讲义。为了方便你复习和记忆，我将内容提炼为四个核心模块，并补充了相关的背景知识、数学推导要点和面试常见考点。

模块一：分类模型基础 (Slide 4-15)

1. 核心概念

- **目标**：将输入向量 \mathbf{x} 分配到 K 个离散类别 \mathcal{C}_k 中的一个。
- **判别函数 (Discriminant Functions)**：直接将 \mathbf{x} 映射到类别的函数。
- **线性判别边界**：
 - 二分类方程： $y(\mathbf{x}) = \mathbf{w}^T \mathbf{x} + w_0$ 。
 - 决策规则：若 $y(\mathbf{x}) \geq 0$ ，判为 \mathcal{C}_1 ；否则判为 \mathcal{C}_2 。

2. 几何意义 (重点记忆)

- **方向**：权重向量 \mathbf{w} 是决策平面的**法向量**，决定了平面的方向。
- **位置**：偏置 w_0 决定了平面的位置。原点到平面的垂直距离为 $\frac{-w_0}{\|\mathbf{w}\|}$ 。
- **距离**：任意点 \mathbf{x} 到决策平面的符号距离为 $r = \frac{y(\mathbf{x})}{\|\mathbf{w}\|}$ 。

3. 多分类策略及其缺陷

- **One-versus-the-rest (一对其余)**：需 $K - 1$ 个分类器。缺陷：会出现“无法确定的区域”（如图 Slide 11 绿色部分）。
- **One-versus-one (一对一)**：需 $K(K - 1)/2$ 个分类器。缺陷：同样存在决策冲突区域。
- **线性多分类判别器 (推荐)**：使用 K 个线性函数 $y_k(\mathbf{x}) = \mathbf{w}_k^T \mathbf{x} + w_{k0}$ 。选 y_k 最大者为结果。
 - **重要特性**：其决策区域是**单连通且凸的 (Convex)**。

模块二：最小二乘法分类 (Least Squares for Classification, Slide 16-23)

1. 原理

- 将分类任务看作回归任务，目标值 t 采用 **1-of-K 编码**（如类别2为 $[0, 1, 0]$ ）。
- 通过最小化平方误差和 (Sum-of-squares error) 来求解参数矩阵 $\tilde{\mathbf{W}}$ 。

- 解: $\tilde{\mathbf{W}} = (\tilde{\mathbf{X}}^T \tilde{\mathbf{X}})^{-1} \tilde{\mathbf{X}}^T \mathbf{T} = \tilde{\mathbf{X}}^\dagger \mathbf{T}$ (伪逆矩阵)。

2. 优缺点分析 (常考点)

- 优点: 有解析解, 计算直接。
 - 缺点 (致命伤):
 - 缺乏鲁棒性: 对离群点 (Outliers) 极其敏感。因为平方误差会给远离边界的正确分类点很大的惩罚, 导致边界偏移 (Slide 22)。
 - “屏蔽”现象 (Masking): 当某些类别的点被夹在中间时, 最小二乘法可能会完全漏掉某些类别 (Slide 23)。
-

模块三: 感知机 (Perceptron, Slide 24-39)

1. 模型定义

- 形式: $y(\mathbf{x}) = f(\mathbf{w}^T \phi(\mathbf{x}))$ 。
- 激活函数: 阶跃函数 (Step function), 输出 $\{+1, -1\}$ 。
- 目标编码: $t = 1$ 对应 \mathcal{C}_1 , $t = -1$ 对应 \mathcal{C}_2 。

2. 感知机准则 (Perceptron Criterion)

- 误差函数: $E_P(\mathbf{w}) = - \sum_{n \in \mathcal{M}} \mathbf{w}^T \phi(\mathbf{x}_n) t_n$ 。
 - 其中 \mathcal{M} 是被错分的样本集合。
 - 正确分类时 $\mathbf{w}^T \phi(\mathbf{x}_n) t_n > 0$, 错误时 < 0 , 故加上负号使误差为正。

3. 优化与收敛

- 算法: 随机梯度下降 (SGD)。
 - 更新规则: $\mathbf{w}^{(\tau+1)} = \mathbf{w}^{(\tau)} + \eta \phi(\mathbf{x}_n) t_n$ 。
 - 直观理解: 如果分错了, 就把权重向正确方向“拨”一下。
 - 感知机收敛定理 (重点):
 - 如果训练数据是线性可分的, 算法保证在有限步内收敛。
 - 如果数据不可分, 算法将永远不会收敛 (产生震荡)。
-

模块四：逻辑回归 (Logistic Regression, Slide 40-70)

1. 核心模型

- **目标**：预测概率 $0 \leq h_w(\mathbf{x}) \leq 1$ 。
- **假设函数**： $h_w(\mathbf{x}) = \sigma(\mathbf{w}^T \mathbf{x}) = \frac{1}{1 + \exp(-\mathbf{w}^T \mathbf{x})}$ 。
- **Sigmoid函数特性**：将实数映射到 $(0, 1)$ 。

2. 决策边界

- **线性**：当 $\mathbf{w}^T \mathbf{x} = 0$ 时，预测概率为 0.5。
- **非线性**：通过引入高级特征（如 x_1^2, x_2^2 ），逻辑回归可以产生圆形成或其他形状的决策边界（Slide 56-58）。

3. 代价函数 (Cost Function) - 重点理解

- **为什么不用最小二乘**？：逻辑回归结合 MSE 会导致非凸 (Non-convex) 函数，容易陷入局部最优，且梯度消失。
- **对数损失 (Log Loss / Cross-Entropy)**：
 - $cost(h_w(\mathbf{x}), t) = -t \log(h_w(\mathbf{x})) - (1 - t) \log(1 - h_w(\mathbf{x}))$
 - **逻辑**：如果 $t = 1$ ，希望 h_w 接近 1；如果 $t = 0$ ，希望 h_w 接近 0。不符则惩罚无限大（Slide 62）。

4. 优化：梯度下降

- **更新公式**： $w_j := w_j - \alpha \frac{1}{m} \sum_{i=1}^m (h_w(\mathbf{x}^{(i)}) - t^{(i)}) x_j^{(i)}$ 。
- **注意**：这个公式的形式竟然与线性回归完全一致，但不同之处在于 $h_w(\mathbf{x})$ 的定义。

复习建议与考点预测

1. 比较题：感知机 vs 逻辑回归。

- **相同**：都是线性分类器，都用梯度下降。
- **不同**：感知机输出离散值（阶跃函数），不可导，只能处理线性可分；逻辑回归输出概率（Sigmoid），可导，可处理概率问题。

2. 几何题：给定 \mathbf{w} 和 w_0 ，判断点的类别或计算到边界的距离。

3. 计算题：执行一步感知机更新（ $\mathbf{w} + \eta \mathbf{x} t$ ）或逻辑回归的梯度计算。

4. 理解题：为什么最小二乘法不适合分类？（Outliers 和 Masking 问题）。

笔记完善建议：

在复习时，可以尝试手画 Slide 22 (Outlier) 和 Slide 34-36 (Perceptron update) 的过程，这能帮你极大地加深对线性模型局限性和工作原理的理解。