

# 机器学习笔记：计算学习理论 (Computational Learning Theory)

## 一、核心框架：PAC 学习模型

PAC (Probably Approximately Correct, 大概近似正确) 是计算学习理论的基础。

### 1. 定义理解：

- 近似正确 (AC): 学习到的假设  $h$  的真误差  $\text{error}_{\text{true}}(h)$  小于一个很小的常数  $\epsilon$ 。
- 大概 (P): 学习器以至少  $1 - \delta$  的概率达到“近似正确”。

2. PAC 可学习性：如果一个概念类  $C$ , 学习器  $L$  可以在多项式时间内（关于  $1/\epsilon, 1/\delta, n, \text{size}(c)$  的多项式）输出满足条件的假设，则称该类是 PAC 可学习的。

3. 核心意义：它不仅要求模型“学得准”，还要求“学得快（时间复杂度）”且“样本够（样本复杂度）”。

## 二、两种误差与过拟合

1. 训练误差 ( $\text{error}_{\text{train}}$ )：在已有训练集  $D$  上的错误率。

2. 真误差 ( $\text{error}_{\text{true}}$ )：在全概率分布  $P(X)$  下，假设  $h$  预测错误的概率。

3. 过拟合 (Overfitting)：当  $\text{error}_{\text{true}}(h) > \text{error}_{\text{train}}(h)$  时发生。

- 过拟合量 =  $\text{error}_{\text{true}}(h) - \text{error}_{\text{train}}(h)$ 。

◦ 理论困境：我们只能观察到训练误差，计算学习理论的目标就是通过训练误差来界定真误差的范围。

## 三、有限假设空间 ( $|H| < \infty$ ) 的样本复杂度

当假设空间  $H$  是有限的时候，我们关注版本空间 (Version Space)，即所有与训练集完全一致 ( $\text{error}_{\text{train}} = 0$ ) 的假设集合。

### 1. Haussler 定理：

- 如果训练样本数  $m$  足够多，版本空间中任何真误差  $> \epsilon$  的假设被保留下来的概率会非常小。
- 概率上限： $|H|e^{-\epsilon m}$ 。

### 2. 样本复杂度公式 (必背)：

为了保证以  $1 - \delta$  的概率达到 PAC 学习，所需的样本数  $m$  满足：

$$m \geq \frac{1}{\epsilon} (\ln |H| + \ln \frac{1}{\delta})$$

- 直观理解：假设空间  $|H|$  越大（模型越复杂），需要的样本量就越多，且呈对数关

系增长。

## 四、不可知学习 (Agnostic Learning)

当目标概念  $c$  不在假设空间  $H$  中时，我们无法找到训练误差为 0 的假设。此时目标是寻找训练误差最小的  $h$ 。

### 1. Hoeffding 不等式应用：

在这种场景下，真误差与训练误差的关系为：

$$\text{error}_{\text{true}}(h) \leq \text{error}_{\text{train}}(h) + \sqrt{\frac{\ln |H| + \ln(1/\delta)}{2m}}$$

2. 结论：随着样本量  $m$  增加，训练误差和真误差的差距会以  $\sqrt{1/m}$  的速度缩小。

## 五、无限假设空间与 VC 维 (VC Dimension)

当假设空间  $H$  是无限的（如线性分类器、神经网络）， $|H|$  无法直接使用，需要引入 **VC 维** 来衡量模型复杂度。

### 1. 基本概念：

- 对分 (Dichotomy): 对集合  $S$  的一种正负标签划分。
- 打散 (Shattering): 如果  $H$  能实现集合  $S$  上所有可能的划分（即  $2^{|S|}$  种），则称  $H$  打散了  $S$ 。
- VC 维定义:  $H$  能够打散的最大有限子集的大小。

2. 线性分类器示例：二维平面上的直线，最多能打散 3 个点（无法打散某些 4 点分布，如异或问题），故其 VC 维为 3。通常， $n$  维空间的线性超平面 VC 维为  $n + 1$ 。

### 3. 基于 VC 维的样本复杂度：

$$m \geq \frac{1}{\epsilon} (4 \log_2(2/\delta) + 8VC(H) \log_2(13/\epsilon))$$

- 关键点：这证明了即便假设空间是无限的，只要 VC 维有限，模型就是 PAC 可学习的。

## 六、典型案例分析

### 1. 布尔合取式 (Conjunctions)：

- $n$  个变量， $|H| = 3^n$ （每个变量有：出现在式中、以否定形式出现、不出现三种状态）。
- 样本复杂度随变量个数  $n$  线性增长。

### 2. 决策树 (Decision Trees)：

- $n$  个布尔特征，假设空间  $|H| = 2^{2^n}$ ，极其庞大。
- 结论：在没有先验假设的情况下，学习完全正确的决策树需要几乎所有的实例 ( $2^n$ )

) , 这就是“没有免费午餐”定理的体现。

---

## 复习建议 (记忆口诀)

- **PAC 两大要素**:  $\epsilon$  是精度,  $\delta$  是稳度。
- **有限空间看  $|H|$** : 样本量  $m$  与  $\ln |H|$  成正比。
- **无限空间看 VC 维**: 只要能打散, 复杂度就有上限。
- **一致性学习器**: 只要训练误差为 0, 样本够多, 真误差一定小。
- **不可知学习**: 目标不在  $H$  内, 就找训练误差最小的那个。